ANKARA ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

BLM4522 Ağ Tabanlı Paralel Dağıtım Sistemleri

Proje 5: Veri Temizleme ve ETL Süreçleri Tasarımı

Kullanılan Veritabanı: University of California, Irvine (UCI) Machine Learning Repository Restaurant & Consumer Data (https://archive.ics.uci.edu/dataset/232/restaurant+consumer+data)

–

Proje Dokümantasyonu

Batuhan DEDE

22290502

Github Linki:

YouTube Linki:

1. GİRİŞ

Bu projede farklı kaynaklardan gelen restoran, kullanıcı ve puanlama verileri PostgreSQL ortamına aktarılarak bir ETL süreci tasarlanmış ve uygulanmıştır. ETL, "Extract, Transform, Load" kavramlarının kısaltmasıdır. Bu kavramlar sırasıyla verinin kaynaktan alınması, dönüştürülmesi ve hedef veritabanı yapısına yüklenmesi anlamına gelmektedir.

Günümüzde veri odaklı sistemlerde bilgiler genellikle tek bir temiz veri tabanında tutulmaz. Veriler farklı dosyalarda, farklı formatlarda ve eksik ya da tutarsız halde bulunabilir. Bu nedenle verinin doğrudan kullanılması yerine önce temizlenmesi ve standardize edilmesi gerekir. Bu projede de aynı ihtiyaç ortaya çıkmıştır. Kullanılan veri seti restoranlar, kullanıcılar ve puanlamalar ile ilgili bilgileri farklı CSV dosyalarında tutmaktadır. Bu nedenle veri entegrasyonu ve veri temizleme işlemleri proje kapsamında temel bir gereklilik haline gelmiştir.

Projenin temel amacı, internetten elde edilen açık bir veri setini PostgreSQL ortamına aktararak veri kalitesi problemlerini tespit etmek, bu problemleri SQL sorguları ile düzeltmek ve son olarak analiz yapılabilecek düzenli bir veri yapısı oluşturmaktır. Projede kurulan yapı sayesinde ham veri, temizlenmiş veri ve raporlama verisi birbirinden ayrılarak daha profesyonel bir ETL akışı oluşturulmuştur.

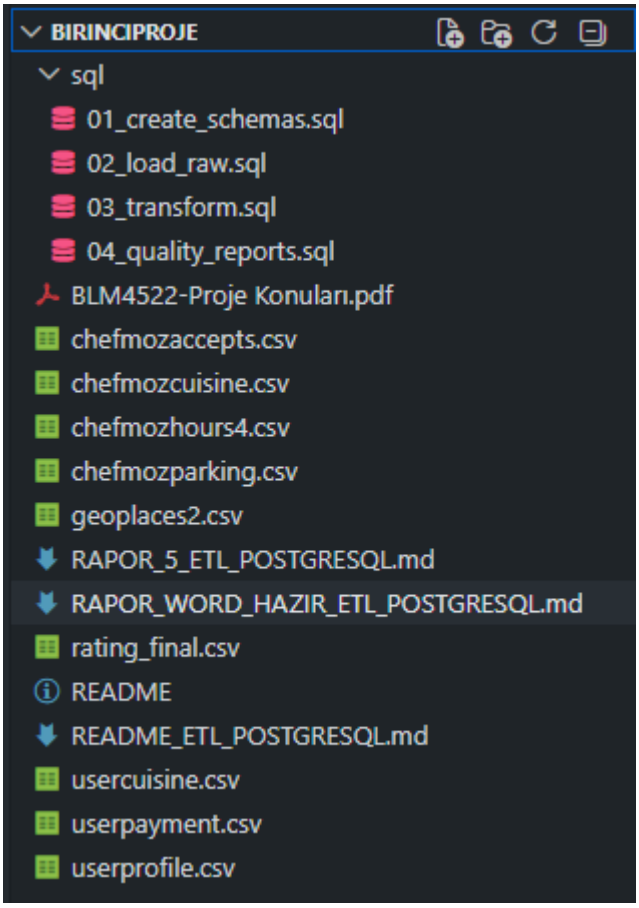

➔ **SQL Dosyaları**

➔ **Veritabanına Dönüştürülen CSV'ler**

2. KULLANILAN VERİ SETİ VE VERİTABANI HAKKINDA BİLGİLER

Projede kullanılan veri seti `Restaurant & consumer data` isimli açık veri setidir. Bu veri seti restoran önerme sistemleri alanında kullanılmak üzere hazırlanmıştır. Veri seti restoranlara ait temel bilgiler, kullanıcı profilleri ve kullanıcıların restoranlara verdiği puanları içermektedir. Veri seti internet üzerinden elde edilmiştir ve birden fazla CSV dosyasından oluşmaktadır.

Veri seti içindeki bütün dosyalar kullanılabilecek durumda olsa da bu projede ETL sürecini en net gösteren üç temel dosya seçilmiştir:

- `geoplaces2.csv`
- `userprofile.csv`
- `rating_final.csv`

`geoplaces2.csv` dosyası restoranlar hakkında temel bilgileri içermektedir. Bu dosyada restoran adı, adres, şehir, eyalet, ülke, fiyat seviyesi, sigara alanı, giyim kuralı, erişilebilirlik ve benzeri bilgiler yer almaktadır.

`userprofile.csv` dosyası kullanıcılar hakkında bilgiler içermektedir. Bu dosyada kullanıcıların konum bilgileri, sigara kullanımı, içecek tercihi, kıyafet tercihi, medeni durum, ilgi alanları, bütçe ve boy-kilo bilgileri bulunmaktadır.

`rating_final.csv` dosyası ise kullanıcıların restoranlara verdiği genel puan, yemek puanı ve servis puanı bilgilerini içermektedir. Bu dosya ETL sürecinin sonunda restoran ve kullanıcı verileri ile birleştirilerek analiz amaçlı final tabloyu oluşturmakta kullanılmıştır.

Bu veri setinin seçilmesinin temel nedeni, farklı kaynaklardan gelen ilişkili veriler içermesi ve veri temizleme açısından uygun eksik ve tutarsız alanlar barındırmasıdır. Böylece proje sadece veri yükleme değil, aynı zamanda veri kalitesi analizi, veri dönüşümü ve raporlama açılarıyla da anlamlı hale gelmiştir.

```
placeID,latitude,longitude,the_geom_meter,name,address,city,state,country,fax,zip,alcohol,smoking_area,dress_code,accessibility,price,url,Rambience,franchise,area,other_services
134999,18.915421,-99.184871,0101000020957F000088568DE356715AC138C0A525FC464A41,Kiku Cuernavaca,Revolucion,Cuernavaca,Morelos,Mexico,?,?,No_Alcohol_Served,none,informal,no_accessibility,medium,kikucuernavaca.com.mx,familiar,f,closed,none
132825,22.1473922,-100.983092,0101000020957F00001AD016568C4858C1243261274BA54B41,puesto de tacos,esquina santos degollado y leon guzman,s.l.p.,s.l.p.,mexico,?,78280,No_Alcohol_Served,none,informal,completely,low,?,familiar,f,open,none
135106,22.1497088,-100.9760928,0101000020957F0000649D6F21634858C119AE9BF528A34B41,El Rincón de San Francisco,Universidad 169,San Luis Potosi,San Luis Potosi,Mexico,?,78000,Wine-Beer,only at bar,informal,partially,medium,?,familiar,f,open,none
132667,23.7526973,-99.1633594,0101000020957F00005D67BCDDED8157C1222A2DC8D84D4941,little pizza Emilio Portes Gil,calle emilio portes gil,victoria ,tamaulipas,?,?,?,No_Alcohol_Served,none,informal,completely,low,?,familiar,t,closed,none
132613,23.7529035,-99.165076,0101000020957F00008EBA2D06DC8157C194E03B7B504E4941,carnitas_mata,lic. Emilio portes gil,victoria,Tamaulipas,Mexico,?,?,No_Alcohol_Served,permitted,informal,completely,medium,?,familiar,t,closed,none
135040,22.135617,-100.969709,0101000020957F00001B552189B84A58C15A2AAEFD2CA24B41,Restaurant los Compadres,Camino a Simon Diaz 155 Centro,San Luis Potosi,SLP,Mexico,?,74000,Wine-Beer,none,informal,no_accessibility,high,?,familiar,f,closed,none
132732,23.7543569,-99.171288,0101000020957F00008A20E615808157C16272FECBF84F4941,Taqueria EL amigo ,Calle Mezquite Fracc Framboyanes,Cd Victoria,Tamaulipas,Mexico,?,87018,No_Alcohol_Served,none,casual,completely,low,?,familiar,f,open,none
132875,22.1499013,-100.9937793,0101000020957F00008A2A0747DE4758C11EB31D2A31A84B41,shi ro ie,?,?,?,?,?,?,Wine-Beer,section,informal,no_accessibility,high,?,familiar,t,open,Internet
132609,23.7602683,-99.1658646,0101000020957F0000A478418BBA8057C133851EB22C4E4941,Pollo_Frito_Buenos_Aires,tampico,victoria,Tamaulipas,Mexico,?,?,No_Alcohol_Served,not permitted,informal,completely,low,?,quiet,t,closed,none
135082,22.151448,-100.915099,0101000020957F0000A29FAF95CD4958C1FEEEBB73A9914B41,la Estrella de Dimas,Villa de Pozos 192 Villa de Pozos,San Luis Potosi,SLP,Mexico,?,78421,No_Alcohol_Served,none,informal,no_accessibility,medium,?,familiar,f,closed,none
135070,22.152918,-100.915164,0101000020957F0000ED435B84934958C1B3CF85FA97914B41,Restaurante 75,Villa de Pozos 4497 Villa de Pozos,San Luis Potosi,SLP,Mexico,?,78421,No_Alcohol_Served,none,informal,no_accessibility,medium,?,familiar,f,closed,none
135069,22.140129,-100.944872,0101000020957F000038E5D546B74A58C18FD29AD0D29A4B41,Abondance Restaurante Bar,Industrias 908 Valle Dorado,San Luis Potosi,SLP,Mexico,?,78399,Wine-Beer,none,informal,no_accessibility,low,?,familiar,f,closed,none
135065,22.14958,-100.999557,0101000020957F000094A6A8E3C14758C174355E6D1DBA94B41,El angel Restaurante,Venustiano Carranza 1625 Jardin,San Luis Potosi,SLP,Mexico,?,78250,Wine-Beer,section,informal,no_accessibility,high,?,familiar,f,closed,none
135076,22.181017,-100.973614,0101000020957F00005657121FAA4358C1A8030D5598A04B41,Restaurante Pueblo Bonito,Mexico 2015 Providencia,San Luis Potosi,SLP,Mexico,?,78395,Wine-Beer,none,informal,no_accessibility,high,?,familiar,f,closed,none
135086,22.141421,-101.013955,0101000020957F0000FA1A0E5A9B4858C17C884C4173AE4B41,Mcdonalds Parque Tangamanga,Lateral Salvador Nava Martinez 3145,San Luis Potosi,SLP,Mexico,?,78290,No_Alcohol_Served,not permitted,informal,no_accessibility,medium,?,familiar,t,closed,none
132870,22.1430781,-100.9354788,0101000020957F0000550FC1FC854A58C16D7D4E35F8974B41,Tortas y hamburguesas el gordo,Ricardo B. Anaya,San Luis Potosi,San Luis Potosi,Mexico,?,?,No_Alcohol_Served,not permitted,informal,no_accessibility,low,?,familiar,f,closed,none
132854,22.1378633,-100.9383273,0101000020957F0000FEC3FB453E4B58C19B4A463617994B41,Sirlone,carr. mexico,San Luis Potosi,San Luis Potosi,Mexico,?,?,Wine-Beer,none,informal,completely,medium,?,familiar,f,closed,none
132937,22.1500193,-100.9799203,0101000020957F0000F9F19DDC3B4858C191B265A83BA44B41,rockabilly ,agustin de iturbide,san luis potosi,san luis potosi,mexico,?,?,Full_Bar,section,informal,completely,low,?,quiet,f,closed,variety
132856,22.1513782,-100.9746337,0101000020957F0000C1B7D30B2C4858C1CE557111A5A24B41,Unicols Pizza,Plaza del Carmen,San Luis Potosi,San Luis Potosi,Mexico,?,?,Wine-Beer,none,informal,completely,low,?,familiar,f,closed,none
132668,23.738212,-99.1519547,0101000020957F000003B195E25F8457C1C535BD04614B4941,TACOS EL GUERO,?,victoria,tamaulipas,mexico,?,?,No_Alcohol_Served,none,informal,completely,low,?,familiar,f,closed,none
135033,22.14161,-100.973142,0101000020957F00000F6240C60B54958C11757339BCCA24B41,Restaurant El Muladar de Calzada,De Guadalupe 460 San Miguelito,San Luis Potosi,SLP,Mexico,?,78399,No_Alcohol_Served,section,informal,no_accessibility,medium,?,familiar,f,closed,none
132862,22.1506429,-100.9870148,0101000020957F0000AF95272CF14758C165B2F91238A64B41,La Posada del Virrey,Av. V. Carranza,San Luis Potosi,San Luis Potosi,Mexico,?,?,Wine-Beer,none,casual,completely,high,?,familiar,f,closed,none
134983,18.948657,-99.235361,0101000020957F0000DEF36F4FC76A5AC162B083D9A0544A41,Restaurant and Bar and Clothesline Carlos N Charlies,Domingo 10 711 El Empleado,Cuernavaca,Morelos,Mexico,?,62250,Full_Bar,section,informal,no_accessibility,high,carlosandcharlies.com,familiar,f,
132851,22.136872,-100.9345736,0101000020957F0000C74DE39C7F4B58C1061F291714984B41,KFC,?,San Luis Potosi,San Luis Potosi,Mexico,?,?,No_Alcohol_Served,not permitted,informal,completely,low,?,familiar,f,closed,none
135013,18.917441,-99.165945,0101000020957F0000D241E94E7B715AC119862B3B1E414A41,Giovannis,40 Norte Civac 1RA. Seccion,Jiutepec,Morelos,Mexico,?,?,No_Alcohol_Served,none,informal,no_accessibility,low,?,familiar,f,closed,none
135042,22.159357,-100.973411,0101000020957F0000C66BB014FC4658C17CFE8D93D2A14B41,Restaurant Oriental Express,Tangamanga 7 Tangamanga,San Luis Potosi,SLP,Mexico,?,78269,No_Alcohol_Served,none,informal,no_accessibility,medium,?,familiar,f,closed,none
132768,18.9257734,-99.2326355,0101000020957F000000DD3546816E5AC119D4BD17FD544A41,Mariscos Tia Licha,avenida salvador montiel ,cuernavaca,morelos,mexico,?,62320,No_Alcohol_Served,not permitted,casual,partially,medium,?,familiar,t,closed,none
132561,23.726819,-99.1265059,0101000020957F000004457BB7AA8657C15F10835CD9444941,cafe ambar,?,?,?,?,?,?,No_Alcohol_Served,none,informal,completely,low,?,familiar,f,closed,none
135045,22.151189,-100.98179,0101000020957F00000B6735CA004858C108FD525CB2A44B41,Restaurante la Gran Via,Venustiano Carranza 560 Centro,San Luis Potosi,SLP,Mexico,?,78000,Wine-Beer,none,casual,no_accessibility,high,lagranvia.com.mx,familiar,f,closed,none
132847,22.1443365,-100.9373825,0101000020957F00004717A23D4744A58C17D1F102970984B41,don burguers,r.b. anaya esq. florencia,slp,slp,mexico,?,?,No_Alcohol_Served,none,informal,no_accessibility,low,?,familiar,f,open,none
135054,22.140626,-100.915657,0101000020957F000011E92CCE714B58C19BF8C0CA75924B41,Restaurante y Pescaderia Tampico,Ricardo B. Anaya 2700 Estrella de Oriente,San Luis Potosi,SLP,Mexico,?,78000S,No_Alcohol_Served,none,informal,no_accessibility,high,?,familiar,f,closed,none
134975,18.940828,-99.215426,0101000020957F000076F426DC856C5AC1CB520721F84E4A41,Rincon del Bife,?,?,?,?,?,?,Full_Bar,section,informal,completely,high,?,familiar,f,closed,variety
135053,22.178931,-101.012861,0101000020957F0000B3C05AB5E54258C180F99573E7AB4B41,La Fontana Pizza Restaurante and Cafe,Satelite 606 Satelite,San Luis Potosi,SLP,Mexico,?,62460,No_Alcohol_Served,section,informal,no_accessibility,high,?,familiar,f,closed,none
135050,22.174887,-100.970825,0101000020957F0000FD78FFF7AD4458C1896A33F029A04B41,Restaurante la Estrella de Dima,Soledad Sn Arboledas de Soledad,Soledad,SLP,Mexico,?,78430,Wine-Beer,none,informal,no_accessibility,high,?,familiar,f,closed,none
```

geoplaces.csv içeriği (toplamda 131 satır)

```
userID,latitude,longitude,smoker,drink_level,dress_preference,ambience,transport,marital_status,hijos,birth_year,interest,personality,religion,activity,color,weight,budget,height
U1001,22.139997,-100.978803,false,abstemious,informal,family,on foot,single,independent,1989,variety,thrifty-protector,none,student,black,69,medium,1.77
U1002,22.150087,-100.983325,false,abstemious,informal,family,public,single,independent,1990,technology,hunter-ostentatious,Catholic,student,red,40,low,1.87
U1003,22.119847,-100.946527,false,social drinker,formal,family,public,single,independent,1989,none,hard-worker,Catholic,student,blue,60,low,1.69
U1004,18.867,-99.183,false,abstemious,informal,family,public,single,independent,1940,variety,hard-worker,none,professional,green,44,medium,1.53
U1005,22.183477,-100.959891,false,abstemious,no preference,family,public,single,independent,1992,none,thrifty-protector,Catholic,student,black,65,medium,1.69
U1006,22.15,-100.983,true,social drinker,no preference,friends,car owner,single,independent,1989,variety,hard-worker,none,student,blue,75,medium,1.8
U1007,22.118464,-100.938256,false,casual drinker,informal,solitary,public,single,independent,1989,variety,thrifty-protector,Catholic,student,purple,60,low,1.59
U1008,22.122989,-100.923811,false,social drinker,formal,solitary,public,single,independent,1989,technology,hard-worker,Catholic,student,green,68,low,1.72
U1009,22.159427,-100.990448,false,abstemious,formal,family,on foot,single,kids,1991,variety,thrifty-protector,Catholic,student,green,75,medium,1.78
U1010,22.190889,-100.998669,false,social drinker,no preference,friends,car owner,married,kids,1987,technology,hard-worker,none,student,green,40,medium,1.67
U1011,23.724972,-99.152856,false,abstemious,no preference,family,public,single,independent,1989,variety,hard-worker,Catholic,student,purple,68,medium,1.78
U1012,18.813348,-99.243697,false,casual drinker,formal,family,public,single,independent,1988,technology,hard-worker,Catholic,student,red,98,medium,1.84
U1013,22.174624,-100.993873,false,abstemious,no preference,friends,public,widow,independent,1982,retro,thrifty-protector,none,professional,blue,80,medium,1.75
U1014,23.751607,-99.170108,false,abstemious,?,friends,public,single,independent,1990,none,hard-worker,Catholic,student,blue,53,medium,1.69
U1015,22.12676,-100.905209,true,social drinker,informal,family,public,single,independent,1989,technology,thrifty-protector,Catholic,student,black,87,medium,1.67
U1016,22.156247,-100.977402,false,casual drinker,informal,friends,on foot,single,independent,1991,eco-friendly,thrifty-protector,Catholic,student,green,70,medium,1.67
```

userprofile.csv içeriği (toplamda 139 satır)

	A	B	C	D	E
1	userID,placeID,rating,food_rating,service_rating				
2	U1077,135085,2,2,2				
3	U1077,135038,2,2,1				
4	U1077,132825,2,2,2				
5	U1077,135060,1,2,2				
6	U1068,135104,1,1,2				
7	U1068,132740,0,0,0				
8	U1068,132663,1,1,1				
9	U1068,132732,0,0,0				
10	U1068,132630,1,1,1				
11	U1067,132584,2,2,2				
12	U1067,132733,1,1,1				
13	U1067,132732,1,2,2				
14	U1067,132630,1,0,1				
15	U1067,135104,0,0,0				
16	U1067,132560,1,0,0				
17	U1103,132584,1,2,1				
18	U1103,132732,0,0,2				
19	U1103,132630,1,2,0				
20	U1103,132613,2,2,2				

ratingfinal.csv içeriği (toplamda 1162 satır)

3. PROJENİN AMACI VE KURULAN ETL MİMARİSİ

Bu projede hedef, veri setini ham haliyle PostgreSQL ortamına almak ve daha sonra katmanlı bir yapıda temizleyerek son kullanıma uygun hale getirmektir. Bunun için üç katmanlı bir ETL mimarisi kurulmuştur:

- `raw` katmanı
- `stg` katmanı
- `dw` katmanı

`raw` katmanında veriler kaynak dosyalardaki haliyle tutulmuştur. Bu aşamada alanlar genellikle `text` tipinde tanımlanmıştır. Bunun nedeni veriyi önce kayıpsız ve bozulmadan sisteme almaktır. Ham veri üzerinde doğrudan analiz yapılmamaktadır.

`stg` katmanı veri temizleme ve dönüştürme katmanıdır. Bu bölümde eksik değerler `NULL` olarak düzenlenmiş, gereksiz boşluklar temizlenmiş, veri tipleri uygun formatlara çevrilmiş ve tutarsız metinler standardize edilmiştir. Bu proje içinde asıl ETL mantığı bu aşamada gerçekleşmiştir.

`dw` katmanı ise son raporlama ve analiz katmanıdır. Bu katmanda restoran, kullanıcı ve puan verileri birleştirilerek tek tabloda toplanmıştır. Böylece sorgular daha kolay yazılabilir ve sonuçlar daha okunabilir hale gelmiştir.

Aşağıdaki sorgu ile bu şemalar oluşturulmuştur:

```
CREATE SCHEMA IF NOT EXISTS raw;
CREATE SCHEMA IF NOT EXISTS stg;
CREATE SCHEMA IF NOT EXISTS dw;
```

Ham restoran tablosu aşağıdaki şekilde oluşturulmuştur:

```
CREATE TABLE raw.geoplaces2 (
    placeid text,
    latitude text,
    longitude text,
    the_geom_meter text,
    name text,
    address text,
    city text,
    state text,
    country text,
    fax text,
    zip text,
```

```
    alcohol text,
    smoking_area text,
    dress_code text,
    accessibility text,
    price text,
    url text,
    rambience text,
    franchise text,
    area text,
    other_services text
);
```

Bu yapı sayesinde önce ham veri korunmuş, sonra temiz veri ayrı bir tabloda üretilmiş ve en sonunda analiz için son tablo hazırlanmıştır. Bu yaklaşım gerçek hayattaki veri mühendisliği projelerinde sık kullanılan güvenli ve düzenli bir yapıdır.

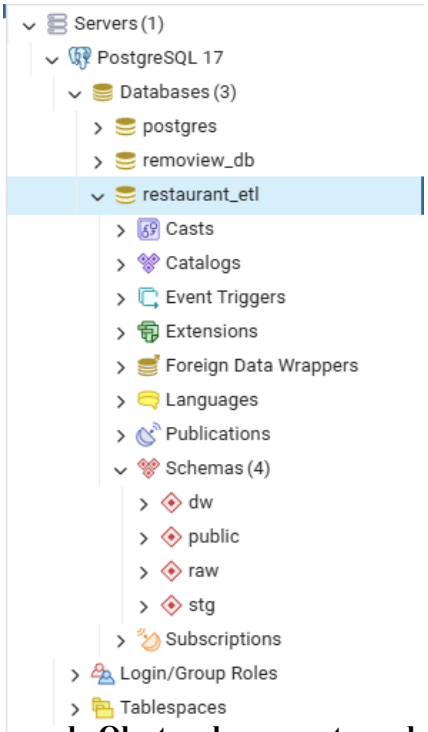

PostgreSQL Ortamında Oluşturulan raw, stg ve dw şemaları

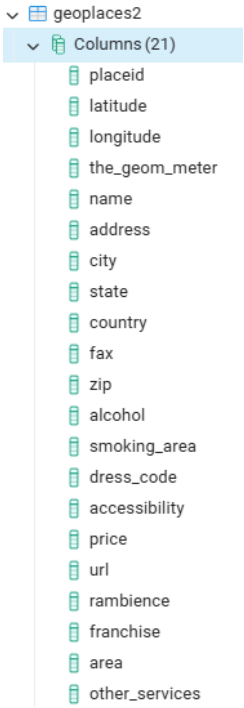

raw.geoplaces2 Ham Veri Tablosunun Kolon Yapısı

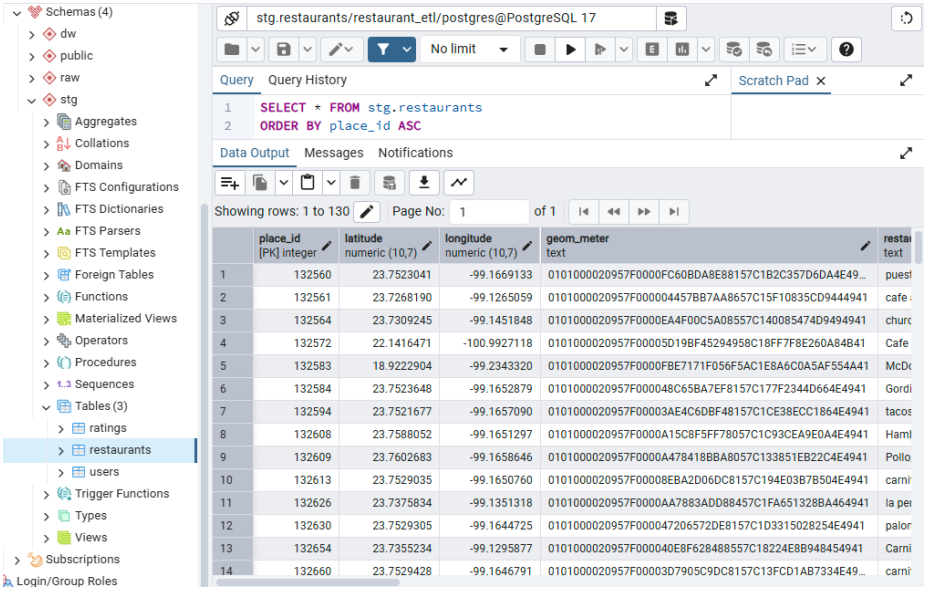

stg.restaurants temiz veri tablosunun kolon ve tablo yapısı

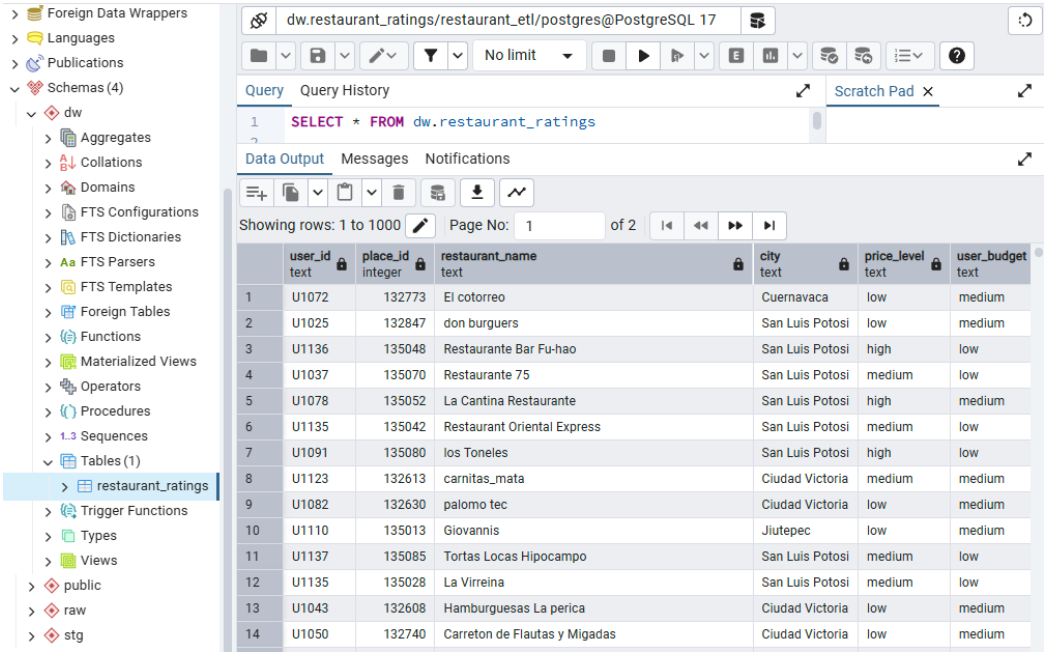

	user_id text	place_id integer	restaurant_name text	city text	price_level text	user_budget text
1	U1072	132773	El cotorreo	Cuernavaca	low	medium
2	U1025	132847	don burguers	San Luis Potosi	low	medium
3	U1136	135048	Restaurante Bar Fu-hao	San Luis Potosi	high	low
4	U1037	135070	Restaurante 75	San Luis Potosi	medium	low
5	U1078	135052	La Cantina Restaurante	San Luis Potosi	high	medium
6	U1135	135042	Restaurant Oriental Express	San Luis Potosi	medium	low
7	U1091	135080	los Toneles	San Luis Potosi	high	low
8	U1123	132613	carnitas_mata	Ciudad Victoria	medium	medium
9	U1082	132630	palomo tec	Ciudad Victoria	low	medium
10	U1110	135013	Giovannis	Jiutepec	low	medium
11	U1137	135085	Tortas Locas Hipocampo	San Luis Potosi	medium	low
12	U1135	135028	La Virreina	San Luis Potosi	medium	low
13	U1043	132608	Hamburguesas La perica	Ciudad Victoria	low	medium
14	U1050	132740	Carreton de Flautas y Migadas	Ciudad Victoria	low	medium

dw.restaurant_ratings final analiz tablosunun kolon ve tablo yapısı

4. VERİ KALİTESİ PROBLEMLERİ VE TESPİT EDİLEN EKSİKLİKLER

Veri seti sisteme alınmadan önce incelendiğinde bazı veri kalitesi problemleri olduğu görülmüştür. Bu problemler ETL sürecinin neden gerekli olduğunu doğrudan göstermektedir. Veri setinde tespit edilen temel problemler şunlardır:

- Birçok alanda `?` karakteri kullanılmıştır
- Bazı metin alanlarında başta veya sonda boşluk bulunmaktadır
- Şehir ve ülke isimleri farklı şekillerde yazılmıştır
- Bazı URL değerleri eksik veya standart dışıdır
- Bazı alanlar mantıksal veri olmasına rağmen metin biçiminde tutulmuştur

Özellikle `geoplaces2.csv` ve `userprofile.csv` dosyalarında eksik verilerin yoğun olduğu görülmüştür. Yapılan veri kalitesi sorguları sonucunda şu eksiklikler tespit edilmiştir:

- restaurants_missing_address = 27
- restaurants_missing_city = 18
- restaurants_missing_country = 28
- restaurants_missing_zip_code = 74
- users_missing_budget = 7
- users_missing_transport = 7

Bu eksikliklerin tespiti için aşağıdaki sorgu kullanılmıştır:

```
SELECT
    'restaurants_missing_address' AS metric,
    COUNT(*) AS missing_count
FROM stg.restaurants
WHERE address IS NULL
UNION ALL
SELECT
    'restaurants_missing_city',
    COUNT(*)
FROM stg.restaurants
WHERE city IS NULL
UNION ALL
SELECT
    'restaurants_missing_country',
    COUNT(*)
FROM stg.restaurants
WHERE country IS NULL
UNION ALL
SELECT
    'restaurants_missing_zip_code',
    COUNT(*)
FROM stg.restaurants
WHERE zip_code IS NULL
UNION ALL
SELECT
    'users_missing_budget',
    COUNT(*)
FROM stg.users
WHERE budget IS NULL
UNION ALL
SELECT
    'users_missing_transport',
    COUNT(*)
FROM stg.users
WHERE transport IS NULL;
```

Bu sonuçlar, ham verinin doğrudan analiz için uygun olmadığını göstermektedir. Örneğin şehir bilgisi olmayan ya da farklı biçimlerde yazılmış restoran kayıtları, doğrudan raporlama yapıldığında yanıltıcı sonuçlar üretebilir. Bu nedenle veri temizleme aşaması projenin en kritik bölümlerinden biri olmuştur.

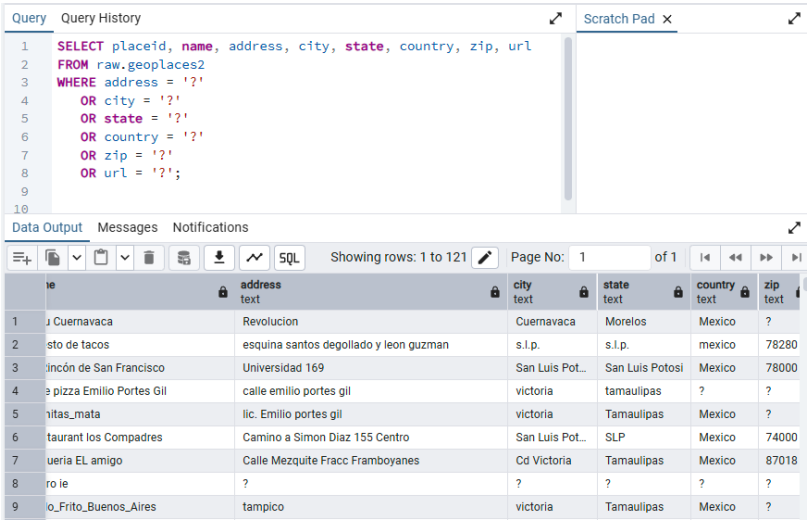

	ne	address text	city text	state text	country text	zip text
1	ı Cuernavaca	Revolucion	Cuernavaca	Morelos	Mexico	?
2	sto de tacos	esquina santos degollado y leon guzman	s.l.p.	s.l.p.	mexico	78280
3	incón de San Francisco	Universidad 169	San Luis Pot...	San Luis Potosi	Mexico	78000
4	e pizza Emilio Portes Gil	calle emilio portes gil	victoria	tamaulipas	?	?
5	nitas_mata	lic. Emilio portes gil	victoria	Tamaulipas	Mexico	?
6	taurant los Compadres	Camino a Simon Diaz 155 Centro	San Luis Pot...	SLP	Mexico	74000
7	ueria EL amigo	Calle Mezquite Fracc Framboyanes	Cd Victoria	Tamaulipas	Mexico	87018
8	ro ie	?	?	?	?	?
9	o_Frito_Buenos_Aires	tampico	victoria	Tamaulipas	Mexico	?

raw.geoplaces2 Tablosunda Eksik Bilgi İçeren Ham Restoran Kayıtları

Query Query History

```sql
SELECT userid, smoker, dress_preference, ambience, transport,
       marital_status, hijos, activity, budget
FROM raw.userprofile
WHERE smoker = '?'
   OR dress_preference = '?'
   OR ambience = '?'
   OR transport = '?'
   OR marital_status = '?'
   OR hijos = '?'
   OR activity = '?'
   OR budget = '?';
```

Scratch Pad ×

Data Output Messages Notifications

Showing rows: 1 to 21 Page No: 1 of 1

	userid text	smoker text	dress_preference text	ambience text	transport text	marital_status text	hijos text	activity text	budget text
1	U1014	false	?	friends	public	single	independent	student	medium
2	U1017	false	formal	family	public	single	?	professional	medium
3	U1024	?	?	?	?	?	?	?	?
4	U1025	false	no preference	family	public	single	?	student	medium
5	U1027	true	no preference	?	public	single	independent	student	low
6	U1031	false	informal	solitary	?	married	kids	unemployed	medium
7	U1033	false	no preference	family	on foot	single	?	student	low
8	U1039	false	no preference	friends	?	single	independent	student	medium

raw.userprofile Tablosunda Eksik Bilgi İçeren Ham Kullanıcı Kayıtları

Query Query History

```sql
SELECT
    'restaurants_missing_address' AS metric,
    COUNT(*) AS missing_count
FROM stg.restaurants
WHERE address IS NULL
UNION ALL
SELECT
    'restaurants_missing_city',
    COUNT(*)
FROM stg.restaurants
WHERE city IS NULL
UNION ALL
SELECT
    'restaurants_missing_country',
    COUNT(*)
FROM stg.restaurants
WHERE country IS NULL
UNION ALL
SELECT
    'restaurants_missing_zip_code',
    COUNT(*)
FROM stg.restaurants
WHERE zip_code IS NULL
UNION ALL
SELECT
    'users_missing_budget',
    COUNT(*)
FROM stg.users
WHERE budget IS NULL
UNION ALL
SELECT
    'users_missing_transport',
    COUNT(*)
FROM stg.users
WHERE transport IS NULL;
```

Data Output Messages Notifications

	metric text	missing_count bigint
1	restaurants_missing_address	27
2	restaurants_missing_city	18
3	restaurants_missing_country	28
4	restaurants_missing_zip_code	74
5	users_missing_budget	7
6	users_missing_transport	7

ETL Sürecinde Tespit Edilen Eksik Veri Sayıları

5. VERİ TEMİZLEME VE DÖNÜŞTÜRME ADIMLARI

Temizleme işlemleri `stg` katmanına veri aktarılırken uygulanmıştır.

5.1. EKSİK DEĞERLERİN TEMİZLENMESİ

Kaynak dosyalarda eksik değerler boş bırakılmak yerine `?` karakteri ile ifade edilmiştir. Bu nedenle ilk olarak bu değerlerin `NULL` olarak yorumlanması sağlanmıştır. Böylece SQL sorgularında eksik alanları saymak, filtrelemek ve raporlamak daha doğru hale gelmiştir.

```
NULLIF(TRIM(address), '?')
```

5.2. BOŞLUK VE METİN TEMİZLİĞİ

Bazı kayıtlarda kelimelerin başında veya sonunda boşluklar bulunmaktadır. Bu durum aynı şehir ya da aynı bilgiyi farklıymış gibi gösterebilir. Bu nedenle `TRIM` kullanılarak gereksiz boşluklar temizlenmiştir.

```
NULLIF(TRIM(city), '?')
```

5.3. VERİ TİPİ DÖNÜŞÜMLERİ

Ham tablolarda tüm alanlar `text` olarak tutulmuştur. Daha sonra bunlar temiz veri katmanında uygun tiplere çevrilmiştir. Enlem ve boylam alanları `numeric`, doğum yılı `integer`, benzeri alanlar uygun veri tiplerine dönüştürülmüştür.

```
NULLIF(TRIM(latitude), '?')::numeric(10,7),
NULLIF(TRIM(longitude), '?')::numeric(10,7),
NULLIF(TRIM(birth_year), '?')::integer
```

5.4. BOOLEAN ALANLARIN DÖNÜŞTÜRÜLMESİ

Kullanıcı sigara bilgisi veya restoranın franchising bilgisi gibi alanlar kaynak dosyalarda metin olarak tutulmuştur. Bu alanlar daha doğru veri modeli oluşturmak için `boolean` alana çevrilmiştir.

```
CASE
    WHEN LOWER(TRIM(smoker)) = 'true' THEN true
    WHEN LOWER(TRIM(smoker)) = 'false' THEN false
    ELSE NULL
END
```

5.5. ŞEHİR VE ÜLKE BİLGİLERİNİN STANDARDİZE EDİLMESİ

Veri setindeki en dikkat çekici problemlerden biri aynı şehrin farklı biçimlerde yazılmasıdır. Örneğin `San Luis Potosi`, `San Luis Potos`, `S.L.P.` ve `Slp` gibi kayıtlar aynı yeri ifade etmesine rağmen farklı değerler olarak görülmektedir. Bu problem analiz sonuçlarını dağıttığı için bu alanlar `CASE` kullanılarak tek bir standarda getirilmiştir.

```
CASE
    WHEN NULLIF(TRIM(city), '?') IS NULL THEN NULL
    WHEN LOWER(TRIM(city)) IN ('san luis potosi', 'san luis potos', 's.l.p.', 's.l.p',
'slp') THEN 'San Luis Potosi'
    WHEN LOWER(TRIM(city)) IN ('victoria', 'cd. victoria', 'cd victoria', 'ciudad
victoria') THEN 'Ciudad Victoria'
    ELSE INITCAP(TRIM(city))
END
```

5.6. URL STANDARDİZASYONU

Bazı restoran kayıtlarında URL bilgisi eksik protokolle tutulmuştur. Bu nedenle gerekli kayıtlarda `http://` ön eki eklenmiştir.

```
CASE
    WHEN NULLIF(TRIM(url), '?') IS NULL THEN NULL
    WHEN POSITION('http' IN LOWER(TRIM(url))) = 1 THEN TRIM(url)
    ELSE 'http://' || TRIM(url)
END
```

5.7. TEKRARLARI VE İLİŞKİSİZ KAYITLARI KONTROL ETME

Puan tablosu aktarılırken kayıtlar `DISTINCT` ile alınmış, daha sonra restoran veya kullanıcı tablosunda eşleşmeyen kayıtlar varsa sistemden çıkarılmıştır. Bu sayede final tabloda yalnızca geçerli ve ilişkili veriler tutulmuştur.

```
INSERT INTO stg.ratings (
    user_id,
    place_id,
    rating,
    food_rating,
    service_rating
)
SELECT DISTINCT
    NULLIF(TRIM(r.userid), '?') AS user_id,
    NULLIF(TRIM(r.placeid), '?')::integer AS place_id,
    NULLIF(TRIM(r.rating), '?')::integer AS rating,
    NULLIF(TRIM(r.food_rating), '?')::integer AS food_rating,
    NULLIF(TRIM(r.service_rating), '?')::integer AS service_rating
FROM raw.rating_final r;
```

Bu işlemler sonucunda veri seti temizlenmiş, uyumlu hale getirilmiş ve son tabloya aktarılmaya hazır duruma gelmiştir.

03_transform.sql Dosyasının Genel Görünümü

6. VERİNİN YÜKLENMESİ VE SON TABLONUN OLUŞTURULMASI

Veri temizleme tamamlandıktan sonra farklı tablolardaki bilgiler birleştirilerek final analiz tablosu üretilmiştir. Bu tabloda kullanıcı, restoran ve puanlama bilgileri birlikte yer almaktadır. Bu yapı sayesinde analiz sorguları daha sade hale gelmiş ve sonuçlar tek noktadan elde edilebilir olmuştur.

Final tablo `dw.restaurant_ratings` olarak oluşturulmuştur. Bu tabloda aşağıdaki alanlar yer almaktadır:

- `user_id`
- `place_id`
- `restaurant_name`
- `city`
- `price_level`
- `user_budget`
- `overall_rating`
- `food_rating`
- `service_rating`

Final tabloya veri aktarmak için aşağıdaki sorgu kullanılmıştır:

```
INSERT INTO dw.restaurant_ratings (
    user_id,
    place_id,
    restaurant_name,
    city,
    price_level,
    user_budget,
    overall_rating,
    food_rating,
    service_rating
)
SELECT
    r.user_id,
    r.place_id,
    res.restaurant_name,
    res.city,
    res.price_level,
    u.budget,
    r.rating,
    r.food_rating,
    r.service_rating
FROM stg.ratings r
JOIN stg.restaurants res
    ON res.place_id = r.place_id
JOIN stg.users u
    ON u.user_id = r.user_id;
```

ETL süreci sonunda elde edilen toplam kayıt sayıları şu şekildedir:

- `raw_geoplaces_row_count = 130`
- `raw_userprofile_row_count = 138`
- `raw_rating_final_row_count = 1161`
- `stg_restaurants_row_count = 130`
- `stg_users_row_count = 138`
- `stg_ratings_row_count = 1161`
- `dw.restaurant_ratings_row_count = 1161`

Bu sonuçlar, veri aktarımı ve dönüşüm sürecinin başarıyla tamamlandığını göstermektedir. Ham tablolarda bulunan verilerin tamamı uygun şekilde temizlenmiş ve final tabloya aktarılmıştır.

```
PS C:\Users\batuh\OneDrive\Masaüstü\Dersler\4.sinif2.donem\AgTabanli\BirinciProje> & "C:\Program Files\PostgreSQL\17\bin\psql.exe" -U postgres -d restaurant_etl -f sql/02_load_raw.sql
Password for user postgres:

TRUNCATE TABLE
TRUNCATE TABLE
TRUNCATE TABLE
COPY 130
COPY 138
COPY 1161
```

Ham Verilerin PostgreSQL Ortamına Yüklenmesi Sırasında Kullanılan Komut

CSV Dosyalarının Başarıyla Yüklenmesini Gösteren COPY Çıktıları

Query | Query History

```
SELECT * FROM dw.restaurant_ratings;
```

Data Output | Messages | Notifications

Showing rows:

	user_id text	place_id integer	restaurant_name text	city text	price_level text	user_budget text	overall_rating integer	food_rating integer	service_rating integer
1	U1072	132773	El cotorreo	Cuernavaca	low	medium	2	1	2
2	U1025	132847	don burguers	San Luis Potosi	low	medium	2	1	1
3	U1136	135048	Restaurante Bar Fu-hao	San Luis Potosi	high	low	1	2	2
4	U1037	135070	Restaurante 75	San Luis Potosi	medium	low	0	0	0
5	U1078	135052	La Cantina Restaurante	San Luis Potosi	high	medium	2	2	2
6	U1135	135042	Restaurant Oriental Express	San Luis Potosi	medium	low	0	0	0
7	U1091	135080	los Toneles	San Luis Potosi	high	low	0	1	1

dw.restaurant_ratings İçinde Oluşturulan Final Analiz Verisinin Görünümü

Query | Query History

```
SELECT 'raw_geoplaces_row_count' AS metric, COUNT(*)::text AS value
FROM raw.geoplaces2
UNION ALL
SELECT 'raw_userprofile_row_count', COUNT(*)::text
FROM raw.userprofile
UNION ALL
SELECT 'raw_rating_final_row_count', COUNT(*)::text
FROM raw.rating_final
UNION ALL
SELECT 'stg_restaurants_row_count', COUNT(*)::text
FROM stg.restaurants
UNION ALL
SELECT 'stg_users_row_count', COUNT(*)::text
FROM stg.users
UNION ALL
SELECT 'stg_ratings_row_count', COUNT(*)::text
FROM stg.ratings
UNION ALL
SELECT 'dw_restaurant_ratings_row_count', COUNT(*)::text
FROM dw.restaurant_ratings;
```

	metric text	value text
1	raw_geoplaces_row_count	130
2	raw_userprofile_row_count	138
3	raw_rating_final_row_count	1161
4	stg_restaurants_row_count	130
5	stg_users_row_count	138
6	stg_ratings_row_count	1161
7	dw_restaurant_ratings_row_count	1161

ETL Süreci Sonunda Oluşan Tablo Kayıt Sayıları

7. ANALİZ SONUÇLARI

ETL süreci tamamlandıktan sonra temizlenmiş veriler üzerinde temel analiz sorguları uygulanmıştır. Bu analizler sayesinde hem veri temizleme işlemlerinin başarılı olduğu gösterilmiş hem de final tablonun raporlama amaçlı kullanılabilir olduğu ortaya konmuştur.

7.1.ŞEHRE GÖRE ORTALAMA PUAN ANALİZİ

Aşağıdaki sorgu ile şehre göre restoran puan ortalamaları hesaplanmıştır:

```
SELECT
    city,
    COUNT(*) AS restaurant_count,
    ROUND(AVG(overall_rating::numeric), 2) AS avg_rating
FROM dw.restaurant_ratings
GROUP BY city
ORDER BY avg_rating DESC, restaurant_count DESC;
```

Bu sorgu sonucunda aşağıdaki şehirler öne çıkmıştır:

- Jiutepec = 1.37
- Cuernavaca = 1.36
- San Luis Potosi = 1.22
- Soledad = 1.06
- Ciudad Victoria = 0.91

Bu sonuçlar aynı şehirlerin farklı biçimlerde yazılmasının giderildiğini ve analiz sonuçlarının daha düzgün hale geldiğini göstermektedir.

7.2.EN YÜKSEK PUANLI RESTORANLAR

Aşağıdaki sorgu ile en yüksek ortalama puana sahip restoranlar elde edilmiştir:

```
SELECT
    restaurant_name,
    city,
    COUNT(*) AS vote_count,
    ROUND(AVG(overall_rating::numeric), 2) AS avg_rating,
    ROUND(AVG(food_rating::numeric), 2) AS avg_food_rating,
    ROUND(AVG(service_rating::numeric), 2) AS avg_service_rating
FROM dw.restaurant_ratings
GROUP BY restaurant_name, city
HAVING COUNT(*) >= 3
ORDER BY avg_rating DESC, vote_count DESC
LIMIT 10;
```

Bu sorgu sonucunda öne çıkan restoranlardan bazıları şunlardır:

- Restaurant Las Mananitas - Cuernavaca
- emilianos - San Luis Potosi
- Michiko Restaurant Japones - San Luis Potosi
- La Estrella de Dimas - San Luis Potosi

Bu analizler ETL sürecinin sonunda elde edilen verinin karar destek ve raporlama amaçları için kullanılabilir hale geldiğini göstermektedir.

8. KARŞILAŞILAN PROBLEMLER VE ÇÖZÜMLER

Proje sırasında bazı teknik problemlerle karşılaşılmıştır. Bu problemler ETL projelerinde gerçek hayatta da sıkça karşılaşılan sorunlardır.

Veritabanının Henüz Oluşturulmamış Olması:

İlk denemede restaurant_etl veritabanına bağlanılmaya çalışıldığında sistem bu veritabanının mevcut olmadığını belirtmiştir. Bu nedenle önce aşağıdaki komut ile veritabanı oluşturulmuştur:

```
CREATE DATABASE restaurant_etl;
```

Karakter Kodlama Problemi:

geoplaces2.csv dosyası ilk denemede UTF-8 olarak yüklenmek istendiğinde hata alınmıştır. Bunun nedeni dosyanın farklı bir karakter kodlamasına sahip olmasıdır. Sorun, ilgili dosyanın WIN1252 kodlaması ile okunması sayesinde çözülmüştür.

```
\copy raw.geoplaces2 FROM './geoplaces2.csv'

WITH (FORMAT csv, HEADER true, ENCODING 'WIN1252');
```

Dağınık Şehir İsimleri:

Şehir isimlerinin farklı biçimlerde gelmesi analiz sonuçlarında aynı yerin birden fazla satırda görünmesine neden olmuştur. Bu problem SQL içinde CASE kullanılarak giderilmiştir.

Bu problemler, ETL projelerinde yalnızca veri yüklemenin yeterli olmadığını; karakter kodlaması, veri tutarlılığı ve veri kalitesi gibi konuların da dikkate alınması gerektiğini göstermektedir.

9. SONUÇ VE DEĞERLENDİRME

Bu projede açık veri kaynağından elde edilen restoran, kullanıcı ve puanlama verileri PostgreSQL ortamına aktarılmıştır. Veriler önce ham haliyle sisteme alınmış, daha sonra veri temizleme ve standardizasyon işlemlerinden geçirilmiş, en son da analiz yapılabilecek düzenli bir tablo yapısına dönüştürülmüştür.

Proje sonucunda farklı dosyalardaki ilişkili veriler birleştirilmiş, eksik alanlar tespit edilmiş, ? ile gösterilen değerler NULL yapılmış, şehir ve ülke gibi alanlarda standardizasyon sağlanmış ve final sorgular için uygun bir veri yapısı kurulmuştur. Ayrıca veri setindeki kayıtlar üzerinden temel analizler yapılarak oluşturulan yapının sadece teknik olarak değil, analitik olarak da kullanışlı olduğu gösterilmiştir.

Bu çalışma, veri temizleme ve ETL süreçlerinin veritabanı projeleri için ne kadar önemli olduğunu ortaya koymaktadır. Ham verinin doğrudan kullanılması durumunda eksik ve tutarsız bilgiler analiz kalitesini düşürebilir. Ancak bu projede uygulanan ETL süreci sayesinde veri daha doğru, daha tutarlı ve daha raporlanabilir hale getirilmiştir.

Gelecek çalışmalarda bu proje şu şekillerde geliştirilebilir:

- Veri setindeki diğer CSV dosyalarının da ETL sürecine dahil edilmesi
- Otomatik ETL akışı için zamanlanmış görevlerin eklenmesi
- Veri kalitesi kontrol sorgularının artırılması
- Tableau, Power BI veya başka bir araç ile görsel raporlama eklenmesi

Sonuç olarak proje konusu kapsamında PostgreSQL kullanılarak gerçek bir veri temizleme ve ETL uygulaması başarıyla gerçekleştirilmiş, proje hedefleri yerine getirilmiş ve raporlanabilir bir veritabanı yapısı elde edilmiştir.